



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

Evolución y transformación de la representación
semántica: del análisis estadístico a las incrustaciones
de aprendizaje profundo

Antecedentes Iniciales del Proyecto

Metodología de la Investigación en
Computación.

AUTOR:

Yandri Alexander Piscocama Jaramillo

DOCENTE:

Ing. Luis Chamba

Loja, Ecuador


26 de mayo del 2026

Declaración de Uso de Inteligencia Artificial Generativa

Yo, **Yandri Alexander Piscocama Jaramillo**, autor del presente ensayo titulado *“Ética, Responsabilidad y Transparencia: Pilares Fundamentales de la Investigación Científica Moderna”*, declaro que en la elaboración de este trabajo académico se emplearon herramientas de inteligencia artificial generativa como apoyo en el proceso investigativo y de redacción. Las herramienta de inteligencia artificial utiliza fue:

- **NotebookLM (Google):** Utilizado para la consulta, análisis y extracción de información académica a partir de las fuentes bibliográficas proporcionadas por el docente.

En todos los casos, el contenido generado fue supervisado, verificado y validado por el autor, quien asume plena responsabilidad por la veracidad, coherencia y originalidad académica del documento final. El uso de estas herramientas se realizó en conformidad con los principios de integridad científica y ética académica establecidos por la Universidad Nacional de Loja.



**Yandri Alexander Piscocama
Jaramillo**

Autor

Loja, 19 de mayo del 2026

Índice General

Declaración de Uso de Inteligencia Artificial Generativa	1
I Antecedentes de la Investigación	4
I.1 La Era Estadística de la Representación de Texto y la Pérdida de Contexto	4
I.1.1 Modelos Simbólicos y Representaciones Esparzas	4
I.1.2 La Hipoteca de la Independencia Semántica	5
I.1.3 El Colapso del Contexto Local y Global	6
I.2 La Revolución de los Embeddings Densos y la Hipótesis Distribucional	6
I.2.1 Del Símbolo al Vector Denso: Word2Vec y GloVe	6
I.2.2 El Desafío de la Polisemia en los Embeddings Estáticos	7
I.2.3 Embeddings Dinámicos y Contextualización: El Efecto BERT .	7
I.3 Desafíos Geométricos Modernos: Anisotropía y Uniformidad del Espacio	
Vectorial	8
I.3.1 El Fenómeno de la Anisotropía: El Problema del Cono Estrecho	8
I.3.2 Aprendizaje Contrastivo como Solución de Ingeniería: DCLR . .	9
I.3.3 Hacia una Geometría Semántica Interpretable	9
Referencias Bibliográficas	11

I. Antecedentes de la Investigación

El desarrollo histórico del Procesamiento de Lenguaje Natural (NLP) se cimentó inicialmente en modelos simbólicos y estadísticos que buscaban transformar la naturaleza discreta del lenguaje en estructuras computables [1]. Antes de la convergencia hacia el aprendizaje profundo, el paradigma dominante consistía en modelos de espacio vectorial (VSM) basados en el conteo de frecuencias, los cuales, aunque efectivos para tareas de clasificación básica, presentaban limitaciones estructurales para capturar la semántica profunda del texto [2].

I.1. La Era Estadística de la Representación de Texto y la Pérdida de Contexto

I.1.1. Modelos Simbólicos y Representaciones Esparzas

Las técnicas primigenias de representación, tales como *One-Hot Encoding* (OHE), asocian cada palabra del vocabulario V con un vector único de dimensión $|V|$, donde un único elemento posee el valor de 1 y el resto permanece en 0 [2]. Formalmente, dada una palabra w_i en un vocabulario $V = \{w_1, w_2, \dots, w_{|V|}\}$, su representación OHE se define como:

$$\vec{e}_{w_i} = [0, \dots, 0, \underbrace{1}_{i\text{-ésima posición}}, 0, \dots, 0] \in \mathbb{R}^{|V|} \quad (\text{I.1})$$

Bajo este esquema, la dimensionalidad del sistema escala de forma lineal y proporcional al tamaño del léxico, lo que genera matrices de dimensionalidad extrema y una redundancia computacional masiva [1]. Se observa que esta aproximación deriva en el fenómeno conocido como la *maldición de la dimensionalidad*, donde la dispersión de los datos (*sparsity*) impide un entrenamiento eficiente en grandes corpus, limitando la escalabilidad de las aplicaciones [2].

El modelo *Bag-of-Words* (BoW) surgió como una evolución para condensar documentos mediante el conteo de frecuencias, reduciendo la representación matricial a una dimensión de N documentos por $|V|$ palabras, pero manteniendo la estructura esparza subyacente [2]. Una refinación posterior, TF-IDF (*Term Frequency–Inverse Document Frequency*), ponderó la relevancia de cada término mediante la expresión:

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \log \left(\frac{|D|}{|\{d \in D : t \in d\}|} \right) \quad (\text{I.2})$$

donde $\text{TF}(t, d)$ representa la frecuencia del término t en el documento d y el segundo factor penaliza los términos de alta frecuencia en todo el corpus D . No obstante, este refinamiento no resolvió el problema estructural de la ortogonalidad vectorial [1].

I.1.2. La Hipoteca de la Independencia Semántica

La limitación técnica más crítica de los modelos estadísticos tradicionales es la **ortogonalidad de sus vectores** [3]. Al asignar un identificador único e independiente a cada palabra, el sistema trata a términos semánticamente relacionados —como “computadora” y “ordenador”— como variables completamente ajenas en el espacio vectorial [1].

Desde una perspectiva matemática, el producto punto entre dos vectores de palabras distintas w_i y w_j siempre resulta en cero:

$$\vec{e}_{w_i} \cdot \vec{e}_{w_j} = 0 \quad \forall i \neq j \quad (\text{I.3})$$

Y por ende, la similitud coseno entre cualquier par de términos distintos colapsa igualmente a cero:

$$\cos(\theta) = \frac{\vec{e}_{w_i} \cdot \vec{e}_{w_j}}{\|\vec{e}_{w_i}\| \cdot \|\vec{e}_{w_j}\|} = 0 \quad \forall w_i \neq w_j \quad (\text{I.4})$$

Esta condición imposibilita que el sistema identifique sinónimos, hipónimos o cualquier jerarquía semántica del mundo real [3]. Como señalan Pilehvar y Camacho-Collados [3], estas representaciones carecen de una métrica de distancia que refleje la similitud conceptual, lo que obliga a los modelos a depender de coincidencias léxicas exactas en lugar de comprender conceptos subyacentes. En consecuencia, cualquier variación morfológica o sinonímica se traduce en una pérdida de señal, frustrando la transferencia de conocimiento geométrico entre términos relacionados [1].

I.1.3. El Colapso del Contexto Local y Global

La arquitectura de modelos como BoW y TF-IDF colapsa ante la semántica profunda debido a la anulación del orden secuencial de las palabras [1]. Al tratar el texto como un “saco” de frecuencias, el software ignora las relaciones sintácticas y las dependencias lógicas que dictan el significado real de una frase [4].

Zhang et al. [1] argumentan que esta incapacidad para capturar el contexto impide resolver problemas fundamentales como la *polisemia*, donde una misma palabra posee múltiples significados según su entorno. Dado que las estadísticas clásicas promedian el uso de un término en todo un documento o corpus, se genera un “conflato de significado” que anula los matices específicos de cada ocurrencia [4]. Sin mecanismos de atención o memoria secuencial, el procesamiento estadístico falla en interpretar dependencias a largo plazo, limitando el entendimiento a fragmentos aislados y superficiales del lenguaje [1].

I.2. La Revolución de los Embeddings Densos y la Hipótesis Distribucional

La transición de los modelos estadísticos hacia el aprendizaje profundo marcó un hito en el Procesamiento de Lenguaje Natural, sustituyendo las representaciones simbólicas discretas por un paradigma basado en espacios vectoriales continuos [5]. Esta evolución permitió que el software dejara de tratar a las palabras como unidades aisladas para interpretarlas como puntos en un hiperespacio matemático donde la geometría dicta el significado [1].

I.2.1. Del Símbolo al Vector Denso: Word2Vec y GloVe

La ruptura del paradigma comenzó con la capacidad de mapear el vocabulario V en un espacio vectorial continuo y denso $\mathbb{R}^d$. Mientras que los modelos clásicos generaban vectores de alta dimensionalidad y esparza proporcionales a $|V|$, los *embeddings* de redes neuronales comprimen esta información en vectores de baja dimensionalidad, típicamente entre $d = 100$ y $d = 500$ para modelos estáticos [1].

Este avance se fundamenta en la **Hipótesis Distribucional**, la cual postula que las palabras que aparecen en contextos similares tienden a compartir significados similares [5]. Bajo este principio, modelos como Word2Vec y GloVe aprenden a posicionar términos semánticamente relacionados in áreas cercanas del espacio vectorial [3].

Una de las propiedades más disruptivas de estos vectores es su **capacidad algebraica**: dado que las dimensiones capturan rasgos semánticos latentes, es posible realizar operaciones matemáticas que reflejan relaciones lógicas del mundo real [1]. El ejemplo canónico de esta propiedad es la operación:

$$\vec{v}_{\text{rey}} - \vec{v}_{\text{hombre}} + \vec{v}_{\text{mujer}} \approx \vec{v}_{\text{reina}} \quad (\text{I.5})$$

En este esquema, la similitud coseno se convierte en la métrica estándar:

$$\cos(\theta) = \frac{\vec{v}_i \cdot \vec{v}_j}{\|\vec{v}_i\| \cdot \|\vec{v}_j\|} \quad (\text{I.6})$$

Un ángulo pequeño entre dos vectores indica una alta correlación semántica, permitiendo que el sistema reconozca sinónimos y analogías sin necesidad de reglas manuales [5].

I.2.2. El Desafío de la Polisemia en los Embeddings Estáticos

A pesar de su eficiencia, los primeros embeddings neuronales poseían una limitación estructural: eran **estáticos**. Como señalan Pilehvar y Camacho-Collados [3], estos modelos asignan un único vector por cada palabra del vocabulario, independientemente de cuántos significados posea el término en la realidad.

Este fenómeno se conoce como el problema de la *confluencia de significado* (*meaning conflation*) [4]. Bajo este paradigma, una palabra polisémica como “banco” (entidad financiera vs. mobiliario) es representada por un vector que es, en esencia, un promedio de todos sus sentidos posibles [3]. Esta colisión de significados distorsiona el espacio semántico, provocando que términos no relacionados —como “dinero” y “madera”— se vean atraídos erróneamente hacia la misma región vectorial debido a su cercanía compartida con el vector de “banco” [4].

I.2.3. Embeddings Dinámicos y Contextualización: El Efecto BERT

La solución definitiva a la polisemia llegó con la introducción de la arquitectura Transformer y el modelo BERT (*Bidirectional Encoder Representations from Transformers*), propuesto por Devlin et al. [6]. A diferencia de sus predecesores, BERT genera embeddings dinámicos, donde la representación de una palabra se calcula en tiempo real para cada ocurrencia específica dentro de su contexto oracional [7].

La transición arquitectónica hacia BERT no fue inmediata: los modelos recurrentes como las LSTM (*Long Short-Term Memory*) representaron un paso intermedio al introducir memoria secuencial, pero procesaban el texto de forma unidireccional y secuencial, limitando su capacidad de capturar dependencias bidireccionales [8]. El mecanismo de Auto-Atención (*Self-Attention*) de los Transformers superó esta restricción al permitir que cada token en una oración influya de forma simultánea sobre todos los demás, independientemente de su distancia posicional en la secuencia [6].

El éxito de BERT radica en tres innovaciones técnicas fundamentales [6]:

- **Atención Bidireccional Profunda:** BERT condiciona la representación de cada token basándose en todo su contexto —tanto a la izquierda como a la derecha— de forma simultánea en todas las capas del modelo, a diferencia de los modelos unidireccionales clásicos [8].
- **Mecanismo de Auto-atención (*Self-Attention*):** Cada palabra en una oración influye sobre las demás, permitiendo que el modelo asigne pesos de importancia α_{ij} y resuelva ambigüedades semánticas de forma dinámica [9].
- **Dimensionalidad Expandida:** Los embeddings dinámicos operan en espacios de mayor complejidad (p.ej. $d = 768$ en BERT_{BASE}), capturando matices sintácticos en las capas inferiores y semánticos en las superiores [10].

I.3. Desafíos Geométricos Modernos: Anisotropía y Uniformidad del Espacio Vectorial

A pesar del éxito de las representaciones dinámicas, la literatura científica reciente ha identificado limitaciones críticas en la topología de los espacios vectoriales generados por los Modelos de Lenguaje Preentrenados (PLMs). El desafío actual de la ingeniería de datos no reside únicamente en la capacidad de contextualización, sino en la **geometría del despliegue de los vectores**, la cual condiciona la fidelidad de las métricas de similitud semántica [11].

I.3.1. El Fenómeno de la Anisotropía: El Problema del Cono Estrecho

Se ha observado que los embeddings generados por modelos como BERT y CLIP no utilizan la totalidad del espacio vectorial disponible. Por el contrario, sufren del fenómeno de **anisotropía**, donde las representaciones se concentran en un cono extremadamente estrecho dentro del hiperespacio [11].

Desde una perspectiva técnica, esto implica que los vectores están altamente correlacionados y comparten una dirección común excesivamente sesgada. El impacto práctico de esta deformación geométrica es el denominado *Problema de Degeneración de la Representación*: al estar confinadas en una región reducida, incluso oraciones con significados disímiles presentan una similitud coseno artificialmente alta, a menudo en rangos superiores a 0,6 [12]. Como resultado, los clasificadores pierden margen de maniobra, lo que deriva en una pérdida de expresividad semántica y una generalización deficiente ante matices lingüísticos finos [11].

I.3.2. Aprendizaje Contrastivo como Solución de Ingeniería: DCLR

Para mitigar el colapso del espacio vectorial, la ingeniería de frontera ha adoptado el **Aprendizaje Contrastivo** (*Contrastive Learning*). El objetivo fundamental de esta técnica es optimizar dos propiedades cardinales: el *alineamiento* (*alignment*) y la *uniformidad* (*uniformity*) [13].

Zhou et al. [13] proponen el marco de trabajo DCLR (*Debiased Contrastive Learning of Unsupervised Sentence Representations*), que introduce estrategias de muestreo de negativos para “limpiar” el espacio semántico. El mecanismo opera mediante dos fuerzas opuestas:

- **Atracción:** Aproximar las representaciones semánticamente cercanas (pares positivos) para mejorar el alineamiento.
- **Repulsión:** Alejar los ejemplos irrelevantes o negativos hacia el exterior para forzar una distribución uniforme en toda la hiperesfera [13].

El uso de negativos basados en ruido gaussiano permite que el modelo explore puntos de no-uniformidad fuera del cono estrecho original, expandiendo el espacio ocupado por las representaciones oracionales y restaurando la isotropía del sistema [13].

I.3.3. Hacia una Geometría Semántica Interpretatable

El camino actual de la investigación sugiere trascender la reducción de la similitud semántica a un simple puntaje escalar. Basándose en la propuesta de Tehenan [14], se busca establecer una **Geometría Semántica** formal fundamentada en la teoría de la información.

Bajo este nuevo paradigma, los embeddings ya no se conciben como puntos aislados, sino como *regiones semánticas* dentro de una hiperesfera unitaria [14]. Se identifica

que el producto punto entre vectores constituye una aproximación de la Información Mutua Puntual (PMI), lo que permite interpretar las operaciones algebraicas como agregaciones de asociaciones estadísticas [14]. Adicionalmente, la identificación de rasgos latentes mediante distribuciones de von Mises–Fisher permite auditar las capas ocultas para comprender qué características lingüísticas reales están capturando los modelos en cada nivel de abstracción [14].

Referencias Bibliográficas

- [1] C. Zhang, B. Peng, X. Sun, Q. Niu, J. Liu, K. Chen, M. Li, P. Feng, Z. Bi, M. Liu, Y. Zhang, X. Song, C. Fei, C. H. Yin, L. K. Yan, H. He, and T. Wang, “From word vectors to multimodal embeddings: Techniques, applications, and future directions for large language models,” 12 2025. [Online]. Available: <http://arxiv.org/abs/2411.05036>
- [2] R. Patil, S. Boit, V. Gudivada, and J. Nandigam, “A survey of text representation and embedding techniques in nlp,” *IEEE Access*, vol. 11, pp. 36 120–36 146, 2023.
- [3] M. T. Pilehvar and J. Camacho-Collados, *Embeddings in Natural Language Processing: Theory and Advances in Vector Representations of Meaning*. Morgan and Claypool Publishers, 11 2020, vol. 13, pp. 1–175.
- [4] M. Apidianaki, “From word types to tokens and back: A survey of approaches to word meaning representation and interpretation,” 2023. [Online]. Available: <https://doi.org/10.1162/coli>
- [5] E. Sezerer and S. Tekir, “A survey on neural word embeddings,” 10 2021. [Online]. Available: <http://arxiv.org/abs/2110.01804>
- [6] J. Devlin, M.-W. Chang, K. Lee, K. T. Google, and A. I. Language, “Bert: Pre-training of deep bidirectional transformers for language understanding,” Tech. Rep. [Online]. Available: <https://github.com/tensorflow/tensor2tensor>
- [7] S. Arora, A. May, J. Zhang, and C. Ré, “Contextual embeddings: When are they worth it?” Tech. Rep. [Online]. Available: <https://github.com/>
- [8] S. Haller, A. Aldea, C. Seifert, and N. Strisciuglio, “Survey on automated short answer grading with deep learning: from word embeddings to transformers,” 3 2022. [Online]. Available: <http://arxiv.org/abs/2204.03503>
- [9] M. Zhao, P. Dufter, Y. Yaghoobzadeh, and H. Schütze, “Findings of the association for computational linguistics quantifying the contextualization of word representations with semantic class probing,” Tech. Rep.

- [10] J. Turton, D. Vinson, and R. E. Smith, “Deriving contextualised semantic features from bert (and other transformer model) embeddings,” Tech. Rep., 2021.
- [11] K. Tyshchuk, P. Karpikova, A. Spiridonov, A. Prutianova, A. Razzhigaev, and A. Panchenko, “On isotropy of multimodal embeddings,” *Information (Switzerland)*, vol. 14, 7 2023.
- [12] S. Dehghan and M. F. Amasyali, “Selfccl: Curriculum contrastive learning by transferring self-taught knowledge for fine-tuning bert,” *Applied Sciences (Switzerland)*, vol. 13, 2 2023.
- [13] K. Zhou, B. Zhang, W. X. Zhao, and J.-R. Wen, “Debiased contrastive learning of unsupervised sentence representations,” Tech. Rep.
- [14] M. Tehenan, “Semantic geometry of sentence embeddings,” Tech. Rep.