

1. Contexto general del problema

El problema se enmarca en el área de Sistemas Inteligentes, específicamente dentro del Procesamiento de Lenguaje Natural (PLN) [1]. Las organizaciones y sistemas de IA enfrentan desafíos críticos para lograr que las máquinas comprendan el lenguaje humano no solo como una secuencia de datos, sino en sus dimensiones sintácticas, semánticas y sentimentales. Este reto es especialmente visible en entornos que requieren alta precisión, como la medicina, las finanzas y la recuperación de información técnica especializada [2], [3].

2. Situación actual basada en evidencia

Diversos estudios han evidenciado que la evolución desde representaciones de texto basadas en reglas y estadísticas (como TF-IDF) hacia embeddings vectoriales (Word2Vec, BERT) ha permitido capturar mejor las relaciones entre palabras [1]. Sin embargo, autores indican que los modelos actuales alcanzan resultados "casi perfectos" solo en datasets estándar de oraciones simples. Persisten limitaciones críticas relacionadas con la polisemia (asignar un solo vector a palabras con múltiples significados) y la incapacidad de los modelos distribucionales para distinguir entre similitud genuina (conceptos que comparten atributos) y relación semántica (conceptos que solo aparecen juntos en el texto) [3].

3. Brecha o vacío identificado

A pesar de los avances, existe una brecha significativa en la robustez de los embeddings ante oraciones complejas y la falta de modelos específicos para dominios técnicos en idiomas distintos al inglés [2]. Específicamente, se ha detectado que el rendimiento de los modelos cae entre un 10% y 20% cuando la complejidad gramatical de la oración aumenta, lo que sugiere que los embeddings actuales aprenden "atajos" heurísticos en lugar de una semántica profunda. Además, la mayoría de los modelos promedian los significados de palabras polisémicas, degradando la precisión en la medición de la relación semántica [4].

4. Problema central

El problema radica en la limitada capacidad de los modelos de embeddings actuales para capturar con precisión la profundidad semántica del lenguaje en estructuras gramaticales complejas y contextos con alta ambigüedad (polisemia), lo cual afecta directamente la fiabilidad de los sistemas de comprensión de lenguaje natural en aplicaciones de misión crítica [3],[5].

5. Consecuencias o impacto

Esta situación genera consecuencias como la pérdida de precisión en la recuperación de información y resultados erróneos en tareas de razonamiento lingüístico. Si no se resuelve, limita el desarrollo de herramientas de traducción automática más humanas,

chatbots de soporte técnico confiables y sistemas de clasificación de documentos en dominios especializados como la medicina o el derecho [2],[3].

6. Actores involucrados

Los principales actores involucrados incluyen a los investigadores en Inteligencia Artificial, desarrolladores de software que implementan soluciones de PLN, organizaciones de salud y finanzas que dependen de análisis de datos textuales, y los usuarios finales de tecnologías de búsqueda y traducción [1] , [5].

7. Variables o elementos clave

Las variables clave asociadas al problema incluyen [1], [3]:

- Representación vectorial (Embeddings): La naturaleza estática o dinámica del vector.
- Complejidad de la oración: Medida a través de índices de legibilidad como Flesch-Kincaid.
- Polisemia: Cantidad de acepciones o sentidos que puede tener una palabra.
- Similitud Semántica Genuina: Grado de coincidencia en rasgos semánticos fundamentales entre dos conceptos .

8. Delimitación del problema

El presente problema se delimita al análisis de embeddings de texto (estáticos y contextualizados) en tareas de medición de similitud y relación semántica, excluyendo aspectos relacionados con hardware de procesamiento o el reconocimiento de voz (audio puro) fuera de su representación textual [2], [4].

9. Vinculación con la sublínea de investigación

Este problema se enmarca dentro de la sublínea de investigación de Inteligencia Artificial, debido a su enfoque en la mejora de las representaciones numéricas del conocimiento para optimizar la comunicación entre humanos y máquinas [5].