



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

**Evolución y Transformación de la Representación
Semántica: Del Análisis Estadístico a los Embeddings
de Aprendizaje Profundo.**

**Evolution and Transformation of Semantic
Representation: From Statistical Analysis to Deep
Learning Embeddings.**

Metodología de la Investigación en
Computación.

AUTOR:

Yandri Alexander Piscocama Jaramillo

TUTOR:

Ing. Luis Chamba-Eras

Loja, Ecuador

2026

Declaración de uso de IA Generativa

Yo, **Yandri Alexander Piscocama Jaramillo**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (IAG) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- Mejora de redacción y estilo académico.
- Generación de ideas preliminares.
- Apoyo en la estructuración del documento.
- Asistencia en traducción técnica.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en:

- **Nivel 1 – Asistencia Lingüística:** Corrección gramatical y mejora de claridad.
- **Nivel 2 – Apoyo en Ideación:** Generación de ideas y esquemas conceptuales.
- **Nivel 3 – Asistencia Técnica:** Apoyo en generación de código y explicaciones técnicas.

No se ha utilizado IA generativa para la generación autónoma de resultados ni para sustituir el análisis crítico del autor.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo.

4. Herramientas utilizadas

Se emplearon modelos de lenguaje (LLMs) y herramientas de asistencia técnica para redacción, estructuración y apoyo conceptual.

5. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la Universidad Nacional de Loja y buenas prácticas internacionales.

6. Declaración final

Declaro que el uso de IA generativa ha sido ético, transparente y complementario, sin comprometer la autoría ni la integridad académica del presente trabajo.

Loja, Ecuador, 13 de mayo del 2026

Yandri Alexander Piscocama Jaramillo
Autor

Índice General

Declaración de uso de IA Generativa	1
1 Preguntas de Investigación	4
1.1 Pregunta Exploratoria	4
1.2 Clasificación de la Literatura	5
Referencias bibliográficas	7

Índice de Tablas

1.1 Matriz de Resumen del Estado del Arte	5
---	---

1. Preguntas de Investigación

1.1. Pregunta Exploratoria

Pregunta: ¿Cómo mejoran los *embeddings* la representación semántica del lenguaje?

Variables

Variable independiente (Causa/Método): Modelos de *embeddings* como técnicas de inteligencia artificial como Word2Vec, GloVe y BERT.

Variable dependiente (Efecto/Resultado): Representación Semántica como captura de relaciones léxicas, sintácticas y contextuales .

1.2. Clasificación de la Literatura

Tabla 1.1: Matriz de Resumen del Estado del Arte

Cita	Referencia (IEEE)	Año	Base	Técnica	Problema	Objetivo	Metodología	Dataset	Resultados	Limitaciones	Aporte PI
[1]	S. Arora et al., "Contextual embeddings: When are they worth it?"	2023	ArXiv	BERT vs GloVe	Costo de BERT	Evaluar valor real	Comparativa empírica	GLUE/NER	Estáticos igualan a BERT en grandes datos	Alto costo computacional	Guía de eficiencia vs precisión
[2]	M. Zhao et al., "Quantifying the contextualization of word representations..."	2020	ACL	Probing (MLP)	Opacidad de BERT	Mapear capas semánticas	Diagnóstico semántico	Wiki-PSE	Capas bajas contextualizan más la sintaxis	Fallo en palabras poco frecuentes	Teoría de transformación semántica
[3]	J. Turton et al., "Deriving contextualised semantic features from BERT..."	2021	ArXiv	Transformers	Modelos de caja negra	Interpretar BERT	Predicción de rasgos	Binder (535w)	BERT supera a modelos estáticos	Tamaño de dataset reducido	Maqueo de semántica humana
[4]	K. Zhou et al., "Debiased contrastive learning of sentence representations"	2022	ACL	DCLR	Anisotropía y sesgo	Optimizar el espacio	Pesos de negativos	STS	Mejora la uniformidad espacial	Dependencia del modelo base	Mejora geométrica del espacio
[5]	M. Apidianaki, "From word types to tokens and back: A survey..."	2023	CL	Survey DSMs	Desconexión teórica	Análisis histórico	Revisión evolutiva	Lit. 1990-2023	Resurgimiento de modelos estáticos	Sesgo en el diseño de prompts	Marco conceptual centralizado
[6]	A. Vasileiou et al., "Explaining text similarity in transformer models"	2023	ACL	BiLRP	Opacidad en similitud	Explicar coincidencias	Atribución de segundo orden	STSb / SICK	Precisión en interacciones de palabras	Elevado costo de cómputo	Explicabilidad de vectores densos
[7]	M. S. Hossain et al., "Semanticcuesync at SemEval-2024..."	2024	SemEval	SBERT / MiniLM	Bajos recursos	Relación semántica	Fine-tuning multilingüe	SemEval-2024	Liderazgo en idioma español	Longitud de oraciones desigual	Estado del arte multilingüe
[8]	T. Wada et al., "Static word embeddings for sentence semantic representation"	2023	ArXiv	PCA / SWE	Ineficiencia de modelos	Estáticos de bajo costo	Descontextualización	MTEB / STS	Compite con modelos de aprendizaje profundo	Ignora el orden de las palabras	Eficiencia en despliegue móvil
[9]	M. Tehenan, "Semantic geometry of sentence embeddings"	2023	ArXiv	InfoNCE / PMI	Opacidad de rasgos	Geometría semántica	Análisis matemático	Dataset sintético	Control de rasgos semánticos	Rasgos semánticos entrelazados	Rigor matemático en embeddings
[10]	E. Sezerer et al., "A survey on neural word embeddings"	2021	IEEE	Survey VSM	Transición técnica	Sistematizar modelos	Clasificación teórica	Literatura seminal	El contexto resuelve la polisemia	Foco excesivo en idioma inglés	Base de antecedentes técnicos
[11]	S. Haller et al., "Survey on automated short answer grading..."	2022	ArXiv	BERT / LSTM	Evaluación ASAG	Analizar calificación	Revisión sistemática	Datasets ASAG	BERT es líder pero no generaliza	Escasez de datos etiquetados	Aplicación en entorno educativo
[12]	C. Zhang et al., "From word vectors to multimodal embeddings..."	2025	ArXiv	Survey LLMs	Sesgos y opacidad	Evolución de modelos	Análisis integral	Benchmarks LLM	Requiere técnicas de compresión	Truncamiento de texto largo	Visión global de modelos LLM
[13]	R. Patil et al., "A survey of text representation and embedding techniques..."	2023	IEEE	Survey NLP	Brecha histórica	Cronología de técnicas	Categorización técnica	1970 a BERT	Vectores densos capturan sintaxis	Falta de interpretabilidad	Base cronológica histórica

[14]	M. T. Pilehvar et al., "Embeddings in NLP: Theory and Advances..."	2020	Book	VSM Theory	Caos metodológico	Sintetizar teoría	Revisión conceptual	Literatura a 2020	Culminación de hipótesis distribucional	Información desactualizada	Justificación teórica sólida
[15]	D. Chandrasekaran et al., "Comparative analysis of word embeddings..."	2021	IEEE	ALBERT / BERT	Complejidad textual	Evaluar robustez	Correlación humana	50 pares complejos	Caída de precisión en complejidad	Tamaño de dataset pequeño	Límites del aprendizaje profundo
[16]	X. Li et al., "Enhancing accuracy of semantic relatedness..."	2021	IEEE	WSME / Doc2Vec	Polisemia léxica	Sentido único	Desambiguación WordNet	SCWS	Alta precisión con bajo costo	Escasez de sentidos raros	Evolución de modelos estáticos
[17]	L. Cagliero et al., "Inferring multilingual domain-specific embeddings..."	2021	IEEE	Regresión lineal	Falta de datos específicos	Transferencia de dominio	Alineación de espacios	Dominios de TI	Alta precisión en recuperación	Limitado a Word2Vec	Adaptación multilingüe de nicho
[18]	J. Devlin et al., "BERT: Pre-training of deep bidirectional transformers..."	2019	Google	BERT (MLM)	Unidireccionalidad	Bidireccionalidad total	Pre-entrenamiento masivo	Wikipedia / Books	SOTA en 11 tareas NLP	Alto costo de entrenamiento	Hito tecnológico fundamental
[19]	Y. Li et al., "Instruction embedding: Latent representations..."	2023	ArXiv	Contrastive	Intención de tarea	Identificar tareas	Muestreo de negativos	Instruction sets	Mejora en selección de prompts	Dependencia de etiquetas	Semántica de instrucciones IA
[20]	J. I. Quiroz-Mercado et al., "Semantic similarity estimation using VSA"	2020	IEEE	VSA (Simbólico)	Fallo en SimLex-999	Modelo híbrido	Codificación de grafos	SimLex-999	Supera a modelos estadísticos	Requiere base externa	Semántica interpretable híbrida

Referencias bibliográficas

- [1] S. Arora, A. May, J. Zhang, and C. Ré, “Contextual embeddings: When are they worth it?” Tech. Rep. [Online]. Available: <https://github.com/>
- [2] M. Zhao, P. Dufter, Y. Yaghoobzadeh, and H. Schütze, “Findings of the association for computational linguistics quantifying the contextualization of word representations with semantic class probing,” Tech. Rep.
- [3] J. Turton, D. Vinson, and R. E. Smith, “Deriving contextualised semantic features from bert (and other transformer model) embeddings,” Tech. Rep., 2021.
- [4] K. Zhou, B. Zhang, W. X. Zhao, and J.-R. Wen, “Debiased contrastive learning of unsupervised sentence representations,” Tech. Rep.
- [5] M. Apidianaki, “From word types to tokens and back: A survey of approaches to word meaning representation and interpretation,” 2023. [Online]. Available: <https://doi.org/10.1162/coli>
- [6] A. Vasileiou and O. Eberle, “Explaining text similarity in transformer models,” Tech. Rep. [Online]. Available: https://github.com/alevas/xai_similarity_
- [7] M. S. Hossain, A. I. Paran, S. H. Shohan, J. Hossain, and M. M. Hoque, “Semanticcuetysync at semeval-2024 task 1: Finetuning sentence transformer to find semantic textual relatedness,” Tech. Rep. [Online]. Available: <https://huggingface.co/sentence-transformers>
- [8] T. Wada, Y. Hirakawa, R. Shimizu, T. Kawashima, and Y. Saito, “Static word embeddings for sentence semantic representation,” Tech. Rep. [Online]. Available: <https://github.com/dleemiller/WordLlama>
- [9] M. Tehenan, “Semantic geometry of sentence embeddings,” Tech. Rep.
- [10] E. Sezerer and S. Tekir, “A survey on neural word embeddings,” 10 2021. [Online]. Available: <http://arxiv.org/abs/2110.01804>

- [11] S. Haller, A. Aldea, C. Seifert, and N. Strisciuglio, “Survey on automated short answer grading with deep learning: from word embeddings to transformers,” 3 2022. [Online]. Available: <http://arxiv.org/abs/2204.03503>
- [12] C. Zhang, B. Peng, X. Sun, Q. Niu, J. Liu, K. Chen, M. Li, P. Feng, Z. Bi, M. Liu, Y. Zhang, X. Song, C. Fei, C. H. Yin, L. K. Yan, H. He, and T. Wang, “From word vectors to multimodal embeddings: Techniques, applications, and future directions for large language models,” 12 2025. [Online]. Available: <http://arxiv.org/abs/2411.05036>
- [13] R. Patil, S. Boit, V. Gudivada, and J. Nandigam, “A survey of text representation and embedding techniques in nlp,” *IEEE Access*, vol. 11, pp. 36 120–36 146, 2023.
- [14] M. T. Pilehvar and J. Camacho-Collados, *Embeddings in Natural Language Processing: Theory and Advances in Vector Representations of Meaning*. Morgan and Claypool Publishers, 11 2020, vol. 13, pp. 1–175.
- [15] D. Chandrasekaran and V. Mago, “Comparative analysis of word embeddings in assessing semantic similarity of complex sentences,” *IEEE Access*, vol. 9, pp. 166 395–166 408, 2021.
- [16] X. Li, S. You, and W. Chen, “Enhancing accuracy of semantic relatedness measurement by word single-meaning embeddings,” *IEEE Access*, vol. 9, pp. 117 424–117 433, 2021.
- [17] L. Cagliero and M. L. Quatra, “Inferring multilingual domain-specific word embeddings from large document corpora,” *IEEE Access*, vol. 9, pp. 137 309–137 321, 2021.
- [18] J. Devlin, M.-W. Chang, K. Lee, K. T. Google, and A. I. Language, “Bert: Pre-training of deep bidirectional transformers for language understanding,” Tech. Rep. [Online]. Available: <https://github.com/tensorflow/tensor2tensor>
- [19] Y. Li, J. Shi, S. Feng, P. Yuan, X. Wang, B. Pan, H. Wang, Y. Hu, and K. Li, “Instruction embedding: Latent representations of instructions towards task identification,” Tech. Rep. [Online]. Available: <https://github.com/Yiwei98/>
- [20] J. I. Quiroz-Mercado, R. Barron-Fernandez, and M. A. Ramirez-Salinas, “Semantic similarity estimation using vector symbolic architectures,” *IEEE Access*, vol. 8, pp. 109 120–109 132, 2020.