



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

**Evolución y Transformación de la Representación
Semántica: Del Análisis Estadístico a los Embeddings
de Aprendizaje Profundo.**

**Evolution and Transformation of Semantic
Representation: From Statistical Analysis to Deep
Learning Embeddings.**

Metodología de la Investigación en
Computación.

AUTOR:

Yandri Alexander Piscocama Jaramillo

TUTOR:

Prof. Luis Chamba-Eras

Loja, Ecuador

2026


Declaración de Uso de Inteligencia Artificial Generativa

Yo, **Yandri Alexander Piscocama Jaramillo**, autor del presente trabajo titulado *“Evolución y Transformación de la Representación Semántica: Del Análisis Estadístico a los Embeddings de Aprendizaje Profundo”*, declaro que en la elaboración de este trabajo académico se emplearon herramientas de inteligencia artificial generativa como apoyo en el proceso investigativo y de redacción.

Las herramienta de inteligencia artificial utiliza fue:

- **NotebookLM (Google):** Utilizado para la consulta, análisis y extracción de información académica a partir de las fuentes bibliográficas proporcionadas por el docente.

En todos los casos, el contenido generado fue supervisado, verificado y validado por el autor, quien asume plena responsabilidad por la veracidad, coherencia y originalidad académica del documento final. El uso de estas herramientas se realizó en conformidad con los principios de integridad científica y ética académica establecidos por la Universidad Nacional de Loja.



**Yandri Alexander Piscocama
Jaramillo**

Autor

Loja, 19 de mayo del 2026

1. Preguntas de Investigación

1.1. Pregunta Exploratoria

Pregunta: ¿Cómo mejoran los *embeddings* la representación semántica del lenguaje?

Variables

Variable independiente (Causa/Método): Modelos de *embeddings* como técnicas de inteligencia artificial como Word2Vec, GloVe y BERT.

Variable dependiente (Efecto/Resultado): Representación Semántica como captura de relaciones léxicas, sintácticas y contextuales [1].

1.2. Pregunta Descriptiva

Pregunta: ¿Cuáles son las características taxonómicas de las técnicas de representación de texto y qué limitaciones técnicas presentan los modelos actuales en términos de sesgo e interpretabilidad?

Variables

Variable independiente (Causa/Método): Categorías Taxonómicas como representaciones basadas en reglas, estadísticas y redes neuronales.

Variable dependiente (Efecto/Resultado): Limitaciones Técnicas como sesgo social, falta de interpretabilidad y costos computacionales [1].

1.3. Pregunta Aplicada

Pregunta: ¿De qué manera la transferencia de transformaciones geométricas desde un idioma de origen permite inferir automáticamente *embeddings* específicos de un dominio para idiomas con escasez de datos?

Variables

Variable independiente (Causa/Método): Transferencia de Transformaciones Geométricas como modelos de regresión aplicados al idioma origen.

Variable dependiente (Efecto/Resultado): Precisión de Inferencia, calidad de los *embeddings* específicos de dominio en el idioma destino [2].

1.4. Pregunta Experimental

Pregunta: ¿En qué medida el incremento de la complejidad sintáctica de las oraciones reduce la precisión (correlación de Pearson y Spearman) de los modelos BERT y ALBERT en tareas de similitud semántica?

Variables

Variable independiente (Causa/Método): Complejidad Sintáctica medida a través de índices de legibilidad como Flesch-Kincaid o Gunning Fog.

Variable dependiente (Efecto/Resultado): Precisión de Similitud Semántica como coeficientes de correlación de Pearson y Spearman obtenidos por BERT y ALBERT [3].

2. Objetivos

2.1. Pregunta Exploratoria

Objetivo General: Analizar los mecanismos de transición de las representaciones de texto desde espacios discretos hacia espacios vectoriales continuos para mejorar la captura de relaciones léxicas, sintácticas y contextuales en sistemas inteligentes.

Objetivos Específicos

OE1.1. Identificar las ventajas técnicas de los vectores densos de baja dimensionalidad frente a métodos tradicionales como *One-Hot Encoding* en términos de eficiencia computacional y reducción de la dispersión de datos.

OE1.2. Describir cómo la hipótesis distribucional permite que los *embeddings* agrupen conceptos semánticamente similares mediante la cercanía geométrica en el hiperespacio.

OE1.3. Explorar la capacidad de los modelos dinámicos contextualizados para resolver la ambigüedad lingüística y la polisemia en comparación con los *embeddings* estáticos.

2.2. Pregunta Descriptiva

Objetivo General: Caracterizar la taxonomía de las técnicas de *embeddings*, basadas en reglas, estadísticas y redes neuronales, y detallar las barreras críticas de interpretabilidad y sesgo reconocidas en la literatura actual.

Objetivos Específicos

OE2.1. Categorizar las técnicas de representación según su arquitectura de aprendizaje, diferenciando entre modelos de rasgos (*feature-based*) y modelos de ajuste fino (*fine-tuning*).

OE2.2. Determinar las limitaciones de interpretabilidad de los modelos basados en redes neuronales profundas y compararlas con la transparencia de las Arquitecturas Simbólicas Vectoriales (VSA).

OE2.3. Sintetizar la evidencia científica sobre la existencia de sesgos sociales y problemas de privacidad en el entrenamiento de grandes modelos de lenguaje pre-entrenados.

2.3. Pregunta Aplicada

Objetivo General: Diseñar un proceso de inferencia multilingüe que utilice transformaciones no lineales en un idioma de origen para adaptar automáticamente los espacios vectoriales de un idioma destino a dominios técnicos especializados.

Objetivos Específicos

OE3.1. Implementar un clasificador binario capaz de discriminar automáticamente términos específicos de dominio, medicina, finanzas o tecnología, para evitar sesgos en la adaptación del modelo general.

OE3.2. Entrenar modelos de regresión multivariante mediante redes neuronales profundas para aprender el mapeo geométrico entre *embeddings* generales y específicos en el idioma fuente.

OE3.3. Evaluar la precisión de los *embeddings* inferidos mediante tareas de recuperación de información bilingüe, comparando los resultados contra un estándar de referencia (*Ground Truth*).

2.4. Pregunta Experimental

Objetivo General: Medir el impacto cuantitativo de la complejidad sintáctica de las oraciones sobre la robustez y precisión de los modelos basados en *Transformers*, BERT, RoBERTa y ALBERT, en tareas de similitud textual.

Objetivos Específicos

OE4.1. Construir un dataset de oraciones complejas y calcular sus índices de legibilidad mediante las métricas de Flesch-Kincaid y Gunning Fog para establecer niveles de control experimental.

OE4.2. Calcular los coeficientes de correlación de Pearson y Spearman entre las predicciones del modelo y los juicios de anotadores humanos expertos para evaluar el desempeño semántico [4].

OE4.3. Comparar estadísticamente la degradación de la precisión entre oraciones simples y oraciones de alta complejidad sintáctica para determinar el límite de eficacia de los *embeddings* actuales [5].

Referencias bibliográficas

- [1] R. Patil, S. Boit, V. Gudivada, and J. Nandigam, “A survey of text representation and embedding techniques in nlp,” *IEEE Access*, vol. 11, pp. 36 120–36 146, 2023.
- [2] L. Cagliero and M. L. Quatra, “Inferring multilingual domain-specific word embeddings from large document corpora,” *IEEE Access*, vol. 9, pp. 137 309–137 321, 2021.
- [3] D. Chandrasekaran and V. Mago, “Comparative analysis of word embeddings in assessing semantic similarity of complex sentences,” *IEEE Access*, vol. 9, pp. 166 395–166 408, 2021.
- [4] J. I. Quiroz-Mercado, R. Barrón-Fernández, and M. A. Ramírez-Salinas, “Semantic similarity estimation using vector symbolic architectures,” *IEEE Access*, vol. 8, pp. 109 120–109 132, 2020.
- [5] X. Li, S. You, and W. Chen, “Enhancing accuracy of semantic relatedness measurement by word single-meaning embeddings,” *IEEE Access*, vol. 9, pp. 117 424–117 433, 2021.